

Université de Lille

# Rapport de scoring de crédit – LoanClub

27/10/2025

INTRODUCTION	2
REVUE DE LITTÉRATURE	3
METHODOLOGIE	4
Description de la base de données	4
Préparation et traitement des données	5
Sélection des variables	6
Séparation des données et correction du déséquilibre	6
Modélisation	7
Construction du score	10
RESULTATS	12
Statistiques descriptives	12
Résultats du modèle	14
Evaluation du modèle	16
Résultats scoring	19
CONCLUSION	23
REFERENCES BIBLIOGRAPHIQUES	24

## INTRODUCTION

La plateforme de financement participatif **LoanClub** met en relation sur un site internet des prêteurs et des emprunteurs. Ce mode de financement s'inscrit dans le **crowdfunding** (financement participatif), pouvant être défini comme un mécanisme par lequel un projet ou un besoin de financement est présenté sur une plateforme en ligne afin de collecter des contributions de montants variés auprès d'un grand nombre d'investisseurs. On distingue classiquement plusieurs modèles de crowdfunding (don, récompense, capital, prêt) ; le présent rapport se situe dans le **crowdfunding par le prêt** (*lending-based crowdfunding* ou *peer-to-peer lending*), où les contributeurs apportent des fonds sous forme de **crédits** qui seront remboursés selon un échéancier contractuel, avec intérêts. La plateforme joue alors un rôle d'intermédiaire : elle agrège l'offre et la demande, facilite l'évaluation du risque et assure le service du prêt (encaissement des échéances, gestion des retards, reporting).

Dans notre contexte, une part importante des demandes de crédit ont pour motif la **consolidation de dette** (*debt consolidation*). Par **consolidation**, on entend le **regroupement** de plusieurs dettes préexistantes (cartes de crédit et prêts à la consommation, etc.) en **un seul prêt** de substitution. Ce genre de prêt permet de **simplifier** le calendrier de remboursement et de **réduire** le coût moyen de la dette via un taux d'intérêt potentiellement plus bas ou un allongement de la maturité qui diminue la mensualité. D'un point de vue risque, même si cette méthode peut se révéler sûre pour les cas où la dette est à court terme (moindre pression sur la trésorerie), elle est néanmoins jugée comme risquée dans d'autres cas. Par exemple, elle peut rallonger la durée d'exposition au risque de défaut ou être le reflet d'une situation d'endettement préalablement tendue. Dans notre jeu de données provenant de la plateforme LoanClub, la finalité « **debt consolidation** » constitue l'un des **motifs de prêt** les plus fréquents. Cela justifie le recours à un modèle performant capable de déceler les prêts risqués parmi la grande variété de situations qui se présentent à nous.

La plateforme dispose déjà d'un **système interne** destiné à estimer la probabilité de défaut des emprunteurs. L'objectif du présent rapport est de proposer un autre **modèle alternatif basé sur la technique du scoring** – outil statistique d'aide à la décision qui classe les individus selon leur niveau de risque.

Ainsi, ce rapport s'organise en plusieurs parties complémentaires. La **première** est une **revue de littérature** synthétique qui a guidé notre démarche. Elle expose les principaux enseignements issus de la recherche en matière d'évaluation du risque de crédit. La **deuxième** partie présente la **méthodologie adoptée**, en détaillant le jeu de données, le traitement des variables et la construction du modèle de régression logistique et du score. La **troisième** partie expose les **résultats empiriques**, en mettant l'accent sur l'interprétation des coefficients, la performance du modèle et du système de scoring qui en découle. Enfin, la **dernière** partie conclut le rapport en **discutant les**

**apports, les limites et les perspectives** du modèle développé pour la plateforme LoanClub.

## REVUE DE LITTÉRATURE

La littérature spécialisée apporte plusieurs éclairages sur ces questions méthodologiques. **Tout d’abord**, en credit scoring, la régression logistique demeure le **modèle de référence** pour les problèmes de classification binaire (Altair, 2022). Ce modèle est privilégié pour sa **simplicité** et son **interprétabilité** : chaque variable explicative y exerce un effet clair sur le risque de défaut (Nguyen *et al.*, 2023; Altair, 2022). En d’autres termes, la contribution de chaque facteur au risque estimé peut être comprise facilement, ce qui est essentiel dans un contexte de décision réglementée.

**Ensuite**, les travaux comparant des approches classiques et des méthodes de **machine learning** soulignent un **arbitrage précision vs interprétabilité**. D’un côté, des méthodes plus sophistiquées (arbres de décision, forêts aléatoires, gradient boosting, réseaux de neurones, etc.) peuvent améliorer légèrement la performance prédictive par rapport au modèle logit classique. De l’autre, ces modèles complexes sont souvent qualifiés de « boîtes noires » car ils offrent peu de visibilité sur la contribution des variables explicatives individuelles au risque (Nguyen *et al.*, 2023). Autrement dit, un modèle de type *Random Forest* ou *XGBoost* peut fournir de meilleures prédictions, mais il sera plus difficile pour un analyste d’en expliquer les résultats à un comité de crédit ou à un régulateur. Cela justifie de privilégier une méthode éprouvée et explicable comme la régression logistique.

**Enfin**, un aspect crucial du scoring est le choix du **seuil de décision** pour classer un emprunteur en défaut probable ou non, à partir de la probabilité estimée par le modèle. La littérature insiste sur le compromis entre le **taux de rappel** (*sensibilité*) et la **précision** (*exactitude*) lors du choix de ce seuil de probabilité (World Bank, 2019). Par exemple, abaisser le seuil de décision augmente le rappel – c’est-à-dire qu’on détecte davantage de véritables défauts (moins de « mauvais payeurs » manqués) – mais cela réduit en contrepartie la précision, car on classe alors à tort plus d’emprunteurs solvables comme risqués (augmentation des faux positifs) (World Bank, 2019). À l’inverse, un seuil plus élevé diminue le nombre de faux positifs mais au risque de laisser passer plus de défauts non détectés. Le choix du seuil optimal dépend donc des **objectifs métier** : la priorité est-elle de minimiser les défauts non anticipés (au risque de refuser plus de bons dossiers), ou bien de trouver un équilibre limitant à la fois les défauts et les rejets injustifiés ? Pour guider ce choix, on peut s’appuyer sur des outils d’évaluation comme la courbe ROC (et son aire sous la courbe AUC) ou l’indicateur **F1-score**, qui offrent une vision du compromis rappel/précision pour chaque seuil possible (World Bank, 2019). Ces métriques issues de la littérature permettent d’identifier un seuil de décision aligné avec la tolérance au risque de la plateforme et ses objectifs en matière d’acceptation de prêts.

Tous ces enseignements ont orienté la méthodologie qui sera décrite dans la section suivante.

## METHODOLOGIE

### Description de la base de données

Pour prédire le risque de défaut, cette étude s'appuie sur la base de données "Loan Club", issue d'une plateforme américaine de prêt peer-to-peer (P2P) mettant en relation directe prêteurs et emprunteurs. L'échantillon analysé comprend 20 000 prêts individuels, décrits par 27 variables portant sur les profils des emprunteurs et les caractéristiques des crédits.

Il convient de noter que cet échantillon présente une **troncature par sélection** : seules les demandes de prêt **acceptées par la plateforme** sont incluses. Les profils à très haut risque, ayant été rejetés en amont, ne sont donc pas représentés. Cette spécificité doit être prise en compte lors de l'interprétation des résultats et limite la généralisation du modèle à l'ensemble des demandeurs de crédit.

Un examen préliminaire confirme l'absence de valeurs manquantes dans l'ensemble de la base, garantissant son exhaustivité et permettant une analyse statistique sans recourir à des méthodes d'imputation.

La variable cible default, relative au statut de remboursement, présente une répartition dichotomique :

- Prêts intégralement remboursés : 16 911 observations (84,6 %)
- Prêts en défaut de paiement : 3 089 observations (15,4 %)

Cette répartition déséquilibrée entre les classes sera prise en compte dans la modélisation afin d'éviter tout biais prédictif.

Parmi les 27 variables initiales, une sélection a été opérée sur la base de critères statistiques pour ne retenir **que 14 variables explicatives** dans l'analyse finale. Ces variables se répartissent en quatre catégories :

1. **Caractéristiques du prêt** : durée, montant, motif
2. **Profil socio-économique de l'emprunteur** : revenu, propriété, ancienneté professionnelle, région
3. **Indicateurs financiers** : ratio dette/revenu, solde des comptes
4. **Historique de crédit** : comptes radiés, retards de paiement, demandes de crédit.

La table 1 ci-dessous présente l'ensemble des variables retenues avec leurs modalités respectives.

**Table 1 Variables retenues avec leurs modalités respectives.**

Variable	Description	Type	Modalités
default	Statut de défaut de paiement	Binaire	0 = Non-défaut ; 1 = Défaut
term	Durée du prêt	Binaire	36 mois ; 60 mois
loan_amnt_q	Montant du prêt (\$)	Catégorielle	[0 ; 8 325] ; (8 325 ; 12 375] ; (12 375 ; 20 000] ; (20 000 ; 35 000]
home_ownership	Statut de propriété	Catégorielle	Propriétaire ; Locataire ; Crédit immobilier
emp3	Ancienneté professionnelle	Catégorielle	< 5 ans ; ≥ 5 ans ; Inconnu
verification_status	Vérification du revenu	Catégorielle	Vérifié ; Non vérifié ; Source vérifiée
purpose_group	Motif du prêt	Catégorielle	Crédit conso. ; Consolidation ; Travaux et autres
num_bc_sats	Nb comptes bancaires ouverts	Catégorielle	0-3 ; 4-6 ; 7+
region	Région géographique	Catégorielle	Ouest ; Sud ; Nord-Est ; Midwest
inq_last_6mths_bin	Demandes de crédit (6 mois)	Binaire	0 = Aucune ; 1+ = Au moins une
dti_q	Ratio dette/revenu (%)	Catégorielle	[0.0 ; 11.3] ; (11.3 ; 16.7] ; (16.7 ; 22.5] ; (22.5 ; 35.0]
chargeoff_bin	Comptes radiés (12 mois)	Binaire	0 = Aucun ; 1+ = Au moins un
num_accts_ever_120_pd_cat	Comptes en retard 120 jours	Binaire	0 = Aucun ; 1+ = Au moins un
num_actv_bc_tl_cat	Nb comptes actifs	Catégorielle	0-2 ; 3-5 ; 6+
annual_inc_q	Revenu annuel (\$)	Catégorielle	[8 000 ; 45 000] ; (45 000 ; 62 000] ; (62 000 ; 86 000] ; (86 000 ; 1 000 000)
avg_cur_bal_q	Solde moyen comptes (\$)	Catégorielle	[0 ; 3 020] ; (3 020 ; 8 302] ; (8 302 ; 20 286] ; (20 286,329 278)

## Préparation et traitement des données

Avant la modélisation, un travail de préparation a été réalisé pour optimiser la qualité des données et faciliter l'interprétation des résultats.

La première étape a consisté à créer la **variable binaire de défaut (default)** à partir du statut du prêt : les prêts en défaut ont été codés 1 et les prêts remboursés 0.

Les variables financières continues ont été discrétisées en quartiles, incluant le montant du prêt, le revenu annuel, le ratio dette/revenu et le solde moyen des comptes, afin de capturer les effets non linéaires et de limiter l'influence des valeurs extrêmes.

Parallèlement, les indicateurs de risque de crédit ont été binarisés pour distinguer la présence ou l'absence d'antécédents défavorables, concernant notamment les retards de paiement sur deux ans, les demandes de crédit récentes, les antécédents publics, les comptes radiés et les retards supérieurs à 120 jours.

Les variables qualitatives ont été regroupées stratégiquement : l'ancienneté professionnelle en trois catégories ("moins de 5 ans", "5 ans ou plus", "inconnu"), les États américains en quatre régions géographiques ("Nord-Est", "Midwest", "Sud", "Ouest"), et les motifs de prêt en trois grandes familles ("Consolidation", "Crédit

consommation", "Travaux et autres"). L'ensemble des variables ainsi transformées a été codé en facteurs.

### Sélection des variables

Après la création de la variable binaire de défaut et le prétraitement des données, l'analyse exploratoire bivariée a permis d'identifier les variables pertinentes à inclure dans le modèle. Étant donné que toutes les variables étaient catégorielles, l'association avec la variable default a été testée à l'aide du test de Chi<sup>2</sup> ou, lorsque les conditions n'étaient pas remplies, via le test exact de Fisher. Sur cette base, les variables présentant une association statistiquement significative avec le défaut ont été retenues.

**La note de crédit (grade)** attribuée par la plateforme et **le taux d'intérêt** appliqué au prêt ont été délibérément exclus du modèle. Ces variables représentent en effet une évaluation du risque déjà réalisée par Loan Club selon son propre système d'évaluation. Les inclure dans notre modèle aurait créé une circularité, en utilisant directement l'évaluation existante pour prédire le risque, au lieu de produire une estimation indépendante basée uniquement sur les caractéristiques fondamentales des emprunteurs.

### Séparation des données et correction du déséquilibre

L'échantillon a été divisé selon une approche train-test split, avec 60 % des données, soit 12 000 observations, allouées à l'apprentissage du modèle, et 40 %, soit 8 000 observations, réservées à sa validation. Afin de préserver la représentativité des classes dans les deux sous-ensembles, la séparation a été stratifiée sur la variable cible. Cette méthode garantit que la proportion de prêts en défaut (15,4 %) et de prêts remboursés (84,6 %) est identique dans les échantillons d'apprentissage et de test, évitant ainsi tout biais lié à une répartition aléatoire déséquilibrée.

Pour remédier au déséquilibre observé entre les classes – seulement 15,4 % de prêts en défaut – une pondération a été appliquée dans l'échantillon d'apprentissage. Cette méthode attribue un poids plus élevé aux observations de la classe minoritaire, permettant au modèle de ne pas être biaisé en faveur des prêts remboursés et d'apprendre de manière équilibrée les déterminants du défaut.

## Modélisation

### Approche par régression logistique

Pour prédire le risque de défaut, nous avons retenu la régression logistique comme modèle principal. Ce choix s'explique par sa capacité à produire des probabilités toujours comprises entre 0 et 1, contrairement au modèle linéaire classique.

L'idée de ce modèle est de relier la probabilité qu'un client fasse défaut (événement  $Y = 1$ ) à un ensemble de caractéristiques  $X$  (revenu, DTI, ancienneté, etc.) par une fonction de lien. La régression logistique modélise **les log-cotes** (log-odds) de l'événement comme une combinaison linéaire des variables :

$$\text{Logit}(p(x)) = \log\left(\frac{p(x)}{1 - p(x)}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

En inversant la fonction logit, on obtient une **probabilité prédite** entre 0 et 1 :

$$p(x) = \frac{1}{1 + \exp(-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p))}.$$

Chaque coefficient  $\beta_j$  s'interprète donc : toutes choses égales par ailleurs, une augmentation d'une unité de  $X_j$  accroît les log-cotes de  $\beta_j$  et **multiplie les cotes** (odds) par  $\exp(\beta_j)$ . Pour une variable catégorielle, la comparaison se fait **par rapport à une modalité de référence**.  $\exp(\beta_m)$  est alors le ratio de cotes entre la modalité  $m$  et la modalité de référence  $v$ .

Le logit présente aussi plusieurs atouts clés pour le scoring : il est **probabiliste** (on peut fixer des seuils selon un coût d'erreur ou une contrainte de rappel), **transparent** (coefficients lisibles, points explicables) et **stable** sous des hypothèses simples (linéarité des log-odds, absence de colinéarités fortes).

### Construction du modèle final

Après l'estimation d'un modèle complet intégrant l'ensemble des variables présélectionnées et la pondération des observations pour corriger le déséquilibre entre classes, une procédure stepwise bidirectionnelle a permis de retenir le modèle le plus parcimonieux selon le critère AIC (Akaike Information Criterion).

Cette approche a permis de conserver uniquement les variables contribuant significativement à la prédiction du défaut.



Le modèle final retenu intègre deux interactions significatives : entre la durée et le montant du prêt d'une part, et entre le statut de propriété et l'ancienneté professionnelle d'autre part.

### Évaluation des performances du modèle

Les performances du modèle ont été évaluées sur l'échantillon de test à l'aide de la courbe ROC (Receiver Operating Characteristic) et de l'AUC (Area Under Curve), mesurant ainsi la capacité globale du modèle à distinguer les prêts en défaut des prêts remboursés. Pour chaque dossier, le modèle fournit une probabilité de défaut. En choisissant un seuil sur cette probabilité (par exemple 0,50), on obtient une décision binaire « défaut » / « non-défaut ». La qualité des prédictions dépend donc à la fois de la performance intrinsèque du modèle et du seuil retenu.

La première brique d'évaluation est la **matrice de confusion**, un tableau à double entrée qui comptabilise :

- les vrais défauts détectés (**vrais positifs, TP**),
- les bons dossiers faussement signalés (**faux positifs, FP**),
- les bons dossiers correctement écartés (**vrais négatifs, TN**),
- les défauts manqués (**faux négatifs, FN**).

À partir de cette matrice, plusieurs indicateurs complémentaires et faciles à interpréter sont calculés :

- **Exactitude (accuracy)** : proportion totale de bonnes prédictions. Elle peut être trompeuse en cas de classes déséquilibrées ; par exemple, prédire systématiquement « non-défaut » peut donner une accuracy élevée (~0,85) tout en ne détectant aucun défaut réel.f

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

C'est pour cette raison qu'on le complète par d'autres indicateurs comme :

- **La précision (PPV)** : elle répond à la question : « parmi les dossiers étiquetés à risque, quelle part est réellement en défaut ? ». Une précision élevée signifie

peu de fausses alertes. Cela nous permet de connaître notre taux de bonnes prédictions parmi nos prédictions positives. Mais ne nous dit pas si notre modèle a pu prédire une bonne partie des défauts. Il se peut très bien que le modèle ait une précision (ppv) de 1 tout en ne captant que 20 % des défauts.

$$PPV = \frac{TP}{FP+TP}$$

- **Le rappel ou sensibilité (TPR)** : permet de pallier ce problème en répondant à la question : « parmi tous les défauts réels, combien en détecte-t-on ? ». Un rappel élevé garantit un filet de sécurité : on rate moins de défauts.

$$Rappel = Sensibilité = \frac{TP}{FN + TP}$$

- **La spécificité (TNR)** : indique la part des non-défauts correctement reconnus. Elle augmente quand on évite d'alerter inutilement sur les bons dossiers.

$$Spécificité = \frac{TN}{FP + TN}$$

- **Le score F1** : est la moyenne harmonique de la précision et du rappel. Il n'est élevé que si les deux le sont simultanément, ce qui en fait un bon critère pour fixer un seuil quand on veut à la fois détecter les défauts et limiter les fausses alertes.

$$F1 = \frac{2 \times (précision \times rappel)}{précision + rappel}$$

- Enfin, **l'indice de Youden (J = sensibilité + spécificité – 1)** résume l'équilibre entre détection et filtrage : le seuil qui maximise Youden fournit un compromis « neutre » lorsque les coûts d'un défaut manqué et d'une fausse alerte sont considérés comparables.

$$J = Sensibilité + Spécificité - 1$$

Il est important de rappeler que ces métriques permettent **d'évaluer la performance du modèle**, mais **ne déterminent pas le seuil final**, qui dépend des objectifs spécifiques de l'entreprise. Par exemple s'il est important pour un laboratoire d'analyse médicale de porter une attention particulière au taux de faux négatifs (il y va de la fiabilité du test et de la santé du patient), il en sera moins pour une banque qui lui

préfèrera le rappel (taux de défauts détectés) à moins que les faux négatifs représentent un coût d'opportunité particulièrement élevé.

## Construction du score

Le modèle que nous avons retenu (noté `modele_final`) contenant nos variables explicatives et des interactions est la base de notre scoring. Cependant, pour calculer le score, on ne retient pas les variables afin de simplifier les choses.

### Calcul du score (de 0 à 100)

#### Étape 1 – Prélèvement des coefficients du modèle

On prélève le coefficient de chaque modalité. Par convention, les modalités de référence ont un coefficient nul.

#### Étape 2 – Calcul des profils de référence : risque le plus faible et risque le plus élevé

Le **profil le moins risqué** : correspond à un individu qui cumule toutes les modalités de référence associées au risque le plus faible (donc pas besoin de réellement le calculer dans notre cas).

Le **profil le plus risqué** : est défini comme l'individu théorique qui cumule, pour chaque variable, la modalité associée au **coefficient le plus élevé** (c'est-à-dire celle qui augmente le plus la probabilité de défaut).

#### Étape 3 – Score individuel

Pour chaque individu, on calcule la **somme des coefficients** correspondant à ses modalités actives.

Cette somme est ensuite **rapportée à la somme des coefficients** du profil le plus risqué, puis **multipliée par 100** afin d'obtenir un **score standardisé** compris entre 0 et 100.

Ainsi un individu au profil moyen comparé à l'individu théorique le plus risqué obtient un score de niveau intermédiaire alors qu'un individu regroupant un grand nombre des caractéristiques risquées tend vers le score de l'individu le plus risqué (100).

Avec cette méthode notre construction garantit :

- Score = 0 pour le profil le moins risqué. Il correspond à l'individu théorique qui combine toutes les modalités de référence
- Score = 100 pour le profil le plus risqué.
- Un continuum d'individus classé dans ce spectre selon leur niveau de similitude avec l'individu le plus risqué.

### Fiche de scoring (points par modalité)

En dressant un tableau de toutes les modalités et les points qui leur sont associés, nous obtenons une fiche de scoring.

Le calcul se fait selon la formule suivante :

$$points = \frac{coef\ modalité}{\sum coef\ max} \times 100$$

De cette manière nous obtenons 0 points pour les modalités de référence et un nombre proportionnel à leur impact sur le risque pour les autres modalités.

Ainsi, pour calculer le **score total** d'un individu, il suffit de simplement de calculer la **somme des points** correspondant à ses modalités.

### **Création des catégories de risque (A → G)**

Une fois le score d'un individu calculé, nous pouvons mettre ce dernier dans une catégorie reflétant son niveau **de risque**. En s'inspirant des modalités précédemment créées par LoanClub, nous avons décidé de créer 7 catégories allant de A (risque faible) à G (risque élevé) mais avec un modèle sous-jacent et des seuils de classifications différents.

Cette catégorisation nous permettra de plus facilement évaluer les résultats de notre démarche en comparant directement la performance de notre classification à celle de la variable grade.

Les seuils séparant les catégories sont fixés **manuellement par tâtonnement**, en tenant compte :

- De la répartition des scores,
- De la progression du taux de défaut (qui doit augmenter de A vers G),
- De la cohérence avec la notation historique de Lending Club
- De notre objectif qui est de diminuer le taux d'erreur

#### **• Contrôles et validation**

Pour valider notre scoring et la classification qui en découle, nous avons procédé en deux temps :

1. Dans un premier, nous avons vérifié si nos résultats étaient cohérents.
  - a. En s'assurant que le score augmentait bien avec le niveau de risque à l'aide d'un boxplot.
  - b. En confrontant nos catégories créées à celles de Loan club.

2. Par la suite, on évalue la performance de nos catégories dans leur capacité à remplir les objectifs fixés. Pour cela nous utilisons les 3 métriques suivantes :
- M1 : cas où un défaut est classé en A ou B (trop bon score) ;
  - M2 : cas où un bon payeur est classé en F ou G (score trop sévère) ;
  - M3 : total des deux erreurs.

## RESULTATS

### Statistiques descriptives

La Table 2 ci-dessous présente les caractéristiques des emprunteurs selon le statut de défaut. La majorité des prêts sont de **36 mois (14 122 individus, soit 70,6 %)**, tandis que les prêts de **60 mois représentent 5 878 individus (29,4 %)**. Le taux de défaut varie également fortement selon la durée du prêt : **11,8 % des emprunteurs de 36 mois ont fait défaut, contre 24,2 % pour les prêts de 60 mois**, cette différence étant **statistiquement significative ( $\chi^2$ ,  $p < 0,001$ )**.

Pour le **ratio dette/revenu (dti\_q)**, les emprunteurs sont répartis de manière équilibrée, chaque classe regroupant environ **25 % des individus**. Le risque de défaut **augmente nettement avec le DTI**, passant de **11,2 % pour les ratios faibles à 19,1 % pour les ratios élevés**, cette variation étant **statistiquement significative ( $\chi^2$ ,  $p < 0,001$ )**.

Pour l'**ancienneté professionnelle**, **32,6 % des emprunteurs ont moins de 5 ans d'ancienneté, 62,9 % ont 5 ans ou plus, et 4,5 % ont une ancienneté non connue**. Le taux de défaut est **le plus élevé chez les emprunteurs dont l'ancienneté est non connue (20,1 %)**, contre **15,4 % pour  $< 5$  ans et 15,1 % pour  $\geq 5$  ans**. De même, le **statut de locataire (17,4 %)** apparaît comme un marqueur de risque significatif, tandis que les emprunteurs appartenant aux **quartiles les plus élevés de revenus et de soldes bancaires (4<sup>e</sup> quartile)** présentent les **taux de défaut les plus faibles, autour de 11-12 %**. **Toutes ces différences observées sont statistiquement significatives ( $\chi^2$ ,  $p < 0,001$ )**.

Globalement, le risque de défaut est plus élevé pour les prêts longs, les emprunteurs aux revenus modestes(cf. **Figure a** ),très endettés, les locataires ou ceux à ancienneté professionnelle incertaine. Ces observations motivent l'analyse multivariée qui suit pour quantifier l'effet simultané de ces facteurs sur le risque de défaut.

**Table 2:Caractéristiques des emprunteurs selon le statut de défaut**

Variable	Catégorie	Non-défaut (n (%))	Défaut (n (%))	Total (n (%))	p-value ( $\chi^2$ )
Ancienneté professionnelle	Moins de 5 ans	5512 (84.6%)	1003 (15.4%)	6515 (32.6%)	< 0.001
	5 ans ou plus	10680 (84.9%)	1905 (15.1%)	12585 (62.9%)	
	Inconnu	719 (79.9%)	181 (20.1%)	900 (4.5%)	
Demandes de crédit (6 mois)	Aucune	9050 (85.7%)	1509 (14.3%)	10559 (52.8%)	< 0.001
	1 ou plus	7861 (83.3%)	1580 (16.7%)	9441 (47.2%)	
Durée du prêt	36 months	12458 (88.2%)	1664 (11.8%)	14122 (70.6%)	< 0.001
	60 months	4453 (75.8%)	1425 (24.2%)	5878 (29.4%)	
Montant du prêt (\$)	[1000 ; 8325]	4358 (86.3%)	694 (13.7%)	5052 (25.3%)	< 0.001
	8 325-12 375	4294 (86.2%)	686 (13.8%)	4980 (24.9%)	
	12 375-20 000	4799 (83.8%)	928 (16.2%)	5727 (28.6%)	
	20 000-35 000	3460 (81.6%)	781 (18.4%)	4241 (21.2%)	
Motif du prêt	Consolidation	10090 (83.8%)	1955 (16.2%)	12045 (60.2%)	< 0.001
	Crédit consommation	4503 (87.2%)	660 (12.8%)	5163 (25.8%)	
	Travaux et autres	2318 (83%)	474 (17%)	2792 (14%)	
Ratio dette/revenu (%)	[0 ; 11.3]	4450 (88.8%)	560 (11.2%)	5010 (25%)	< 0.001
	(11.3-16.7]	4284 (85.7%)	717 (14.3%)	5001 (25%)	
	(16.7-22.5]	4133 (82.8%)	858 (17.2%)	4991 (25%)	
	(22.5 ; 35]	4044 (80.9%)	954 (19.1%)	4998 (25%)	
Revenu annuel (\$)	[8 000 ; 45 000]	4155 (81.6%)	939 (18.4%)	5094 (25.5%)	< 0.001
	(45 000 ; 62 000]	4089 (83%)	839 (17%)	4928 (24.6%)	
	(62 000 ; 86 000]	4270 (85.3%)	733 (14.7%)	5003 (25%)	
	(86 000 ; 1e+06]	4397 (88.4%)	578 (11.6%)	4975 (24.9%)	
Revenu vérifié	Non vérifié	4901 (88%)	670 (12%)	5571 (27.9%)	< 0.001
	Source vérifiée	4500 (82.9%)	926 (17.1%)	5426 (27.1%)	
	Vérifié	7510 (83.4%)	1493 (16.6%)	9003 (45%)	
Région	Sud	5748 (84.2%)	1078 (15.8%)	6826 (34.1%)	0.001
	Nord-Est	3615 (83.6%)	711 (16.4%)	4326 (21.6%)	
	Midwest	2642 (83.8%)	510 (16.2%)	3152 (15.8%)	
	Ouest	4906 (86.1%)	790 (13.9%)	5696 (28.5%)	
Solde moyen des comptes (\$)	[0 ; 3 020]	4138 (82.7%)	864 (17.3%)	5002 (25%)	< 0.001
	(3 020 ; 8 302]	4153 (83.1%)	845 (16.9%)	4998 (25%)	
	(8 302 ; 20 286]	4224 (84.5%)	776 (15.5%)	5000 (25%)	
	(20 286 ; 329 278]	4396 (87.9%)	604 (12.1%)	5000 (25%)	
Statut de propriété(logement)	Crédit immobilier	9183 (86.1%)	1486 (13.9%)	10669 (53.3%)	< 0.001
	Propriétaire	1542 (83.7%)	301 (16.3%)	1843 (9.2%)	
	Locataire	6186 (82.6%)	1302 (17.4%)	7488 (37.4%)	
Comptes radiés (12 mois)	Pas d'antécédent	16817 (84.5%)	3076 (15.5%)	19893 (99.5%)	0.417
	Antécédent	94 (87.9%)	13 (12.1%)	107 (0.5%)	

**Source: Base de données Loan club**




Figure a : Durée & Revenu annuel vs Statut de remboursement

## Résultats du modèle

Les résultats du modèle logistique final (Table 3) sont présentés sous forme d'odds ratios avec leurs intervalles de confiance à 95 %.

La durée du prêt apparaît comme un facteur central : les emprunteurs ayant souscrit un prêt sur 60 mois ont 1,8 fois plus de chances d'être en défaut que ceux ayant un prêt sur 36 mois. Ce résultat suggère qu'un allongement de la durée du crédit s'accompagne souvent d'une plus grande vulnérabilité financière, traduisant une **capacité de remboursement plus fragile**.

Le risque de défaut augmente également avec le montant du prêt : il est 1,17 fois plus élevé dans le troisième quartile et 1,38 fois plus élevé dans le quartile le plus élevé par rapport aux montants les plus faibles. Cela traduit une exposition accrue au risque pour les emprunteurs ayant des encours plus importants, possiblement liée à **une tension sur le budget ou un effort financier excessif**.

Le statut résidentiel est également révélateur : les locataires présentent 1,34 fois plus de chances d'être en défaut que les propriétaires. Ce résultat s'interprète comme le reflet d'une **stabilité économique et patrimoniale moindre** chez les ménages locataires, souvent associés à des revenus plus volatils ou à une épargne plus limitée.

L'ancienneté professionnelle joue aussi un rôle : les individus dont la durée d'emploi est inconnue ont 1,65 fois plus de risques d'être en défaut, ce qui peut traduire une **incertitude sur la stabilité de leur emploi** ou une **opacité dans leur profil financier**. L'interaction entre le fait d'être propriétaire et une ancienneté inférieure à cinq ans

accentue encore ce risque (1,39 fois plus élevé), soulignant qu'un statut résidentiel favorable ne compense pas un manque d'expérience ou de stabilité professionnelle.

Sur le plan des revenus, la relation est nette : les emprunteurs du premier quartile de revenu ont 2,16 fois plus de chances d'être en défaut que ceux du quartile supérieur, et ceux du deuxième quartile 1,63 fois plus. Autrement dit, la **capacité de remboursement augmente avec le revenu**, confirmant que les ménages les plus modestes sont structurellement plus exposés au risque de non-remboursement.

Le ratio dette/revenu (DTI) renforce cette logique : les emprunteurs du troisième quartile ont 1,42 fois plus de risques de défaut que ceux du premier, et ceux du quatrième quartile 1,35 fois plus. Cela montre que **plus le poids de la dette dans le revenu est élevé, plus le risque de défaut augmente**, cohérent avec une contrainte budgétaire accrue.

D'autres variables financières confirment cette dynamique. Les emprunteurs ayant fait au moins une demande de crédit récente présentent 1,35 fois plus de chances d'être en défaut, suggérant une **dépendance accrue au crédit**. Ceux possédant six comptes actifs ou plus ont un risque 1,59 fois plus élevé, ce qui peut refléter une **multiplication des engagements financiers** difficile à maîtriser.

Enfin, l'interaction entre la durée et le montant du prêt révèle un effet cumulatif : pour les prêts longs et de montants élevés, la probabilité de défaut est 1,59 fois plus élevée. Cela illustre que **les conditions de prêt plus lourdes (durée et montant) amplifient mutuellement le risque**, traduisant un profil d'emprunteur plus fragile et une soutenabilité du crédit plus faible.

Dans l'ensemble, ces résultats confirment que le **risque de défaut résulte avant tout d'une capacité de remboursement contrainte**, elle-même influencée par la structure du prêt (montant et durée), la situation économique (revenus, endettement) et la stabilité financière et professionnelle de l'emprunteur.



**Table 3 : OR & IC du modèle logistique final**

Variable	OR	IC 95%	
Durée 60 mois	1.78	[1.32-2.42]	***
Montant prêt 8 325-12 375	0.97	[0.89-1.05]	
Montant prêt 12 375-20 000	1.17	[1.06-1.28]	**
Montant prêt 20 000-35 000	1.38	[1.22-1.57]	***
Propriétaire	0.93	[0.82-1.05]	
Locataire	1.34	[1.22-1.46]	***
Ancienneté < 5 ans	1.06	[0.98-1.16]	
Ancienneté inconnue	1.65	[1.38-1.97]	***
Revenu non vérifié	1.07	[0.98-1.16]	
Revenu source vérifiée	1.22	[1.14-1.30]	***
Motif Consolidation	1.21	[1.13-1.29]	***
Motif Travaux/Autres	1.54	[1.41-1.69]	***
Nb comptes ouverts 0-3	1.21	[1.08-1.35]	**
Nb comptes ouverts 4-6	1.14	[1.04-1.25]	**
Région Sud	1.19	[1.11-1.27]	***
Région Nord-Est	1.27	[1.17-1.37]	***
Région Midwest	1.24	[1.14-1.35]	***
Demandes crédit 6 mois ≥1	1.35	[1.28-1.43]	***
DTI 11.3-16.7	1.18	[1.09-1.28]	***
DTI 16.7-22.5	1.42	[1.31-1.53]	***
DTI 22.5-35	1.35	[1.24-1.47]	***
Comptes radiés ≥1	2.20	[1.45-3.38]	***
Retard 120 jours ≥1	1.13	[1.05-1.21]	***
Comptes actifs 3-5	1.12	[1.03-1.21]	**
Comptes actifs 6+	1.59	[1.41-1.80]	***
Revenu 8 000-45 000	2.16	[1.96-2.38]	***
Revenu 45 000-62 000	1.63	[1.49-1.78]	***
Revenu 62 000-86 000	1.32	[1.22-1.43]	***
Solde moyen 0-3 020	1.22	[1.10-1.36]	***
Solde moyen 3 020-8 302	1.14	[1.04-1.26]	**
Solde moyen 8 302-20 286	1.05	[0.96-1.14]	
Interaction : Durée 60 mois × Montant 8 325-12 375	1.38	[0.99-1.90]	
Interaction : Durée 60 mois × Montant 12 375-20 000	1.26	[0.91-1.73]	
Interaction : Durée 60 mois × Montant 20 000-35 000	1.58	[1.14-2.19]	**
Interaction : Propriétaire × Ancienneté < 5 ans	1.39	[1.13-1.72]	**
Interaction : Locataire × Ancienneté < 5 ans	0.90	[0.80-1.02]	
Interaction : Propriétaire × Ancienneté inconnue	1.00	[0.69-1.44]	
Interaction : Locataire × Ancienneté inconnue	0.98	[0.74-1.28]	
Pseudo-R <sup>2</sup> de Nagelkerke	0.182		
*** $p < 0.001$ , ** $p < 0.01$ , * $p < 0.05$			

## Evaluation du modèle

La courbe ROC montre une performance satisfaisante du modèle, nettement supérieure à celle d'un modèle aléatoire (représenté par la diagonale). L'aire sous la courbe ( $AUC \approx 0,65$ ) indique une **capacité de discrimination correcte** : le modèle distingue globalement bien les emprunteurs susceptibles de faire défaut de ceux qui remboursent correctement. En d'autres termes, dans environ **65 % des cas**, un emprunteur présentant un défaut aura une probabilité prédite plus élevée qu'un emprunteur sans défaut. C'est cohérent avec la nature hétérogène et bruitée des données et cela nous montre que le modèle arrive à capter des signaux de

risques et est capable de constituer une **base solide pour un scoring** et une catégorisation.




Figure b : Courbe ROC (Source : Données publiques LoanClub + Traitement personnel)

Une autre manière d'évaluer la performance du modèle consiste à tracer les courbes des différentes métriques en fonction du **seuil de classification** adopté. Lorsque ce seuil est très bas, **presque tous les individus sont classés comme "à risque"** : la **sensibilité** atteint alors 1 (tous les défauts sont détectés, puisque presque tout le monde est considéré comme risqué), mais la **spécificité** s'effondre (le modèle génère de nombreux faux positifs, même parmi les emprunteurs les plus sûrs), tandis que la **précision** reste proche de la **prévalence des défauts**.

À l'inverse, avec un **seuil très élevé**, la précision et la spécificité montent, mais la sensibilité chute : on passe à côté d'une grande partie des défauts. Entre ces extrêmes, on observe une **zone médiane** où **F1** culmine et où **Youden** est maximal ; c'est typiquement là que se trouve le **meilleur compromis** pour une utilisation générale. Dans nos résultats, ce point se situe légèrement en dessous de 0,50, les deux critères (F1-max et Youden) étant très proches.

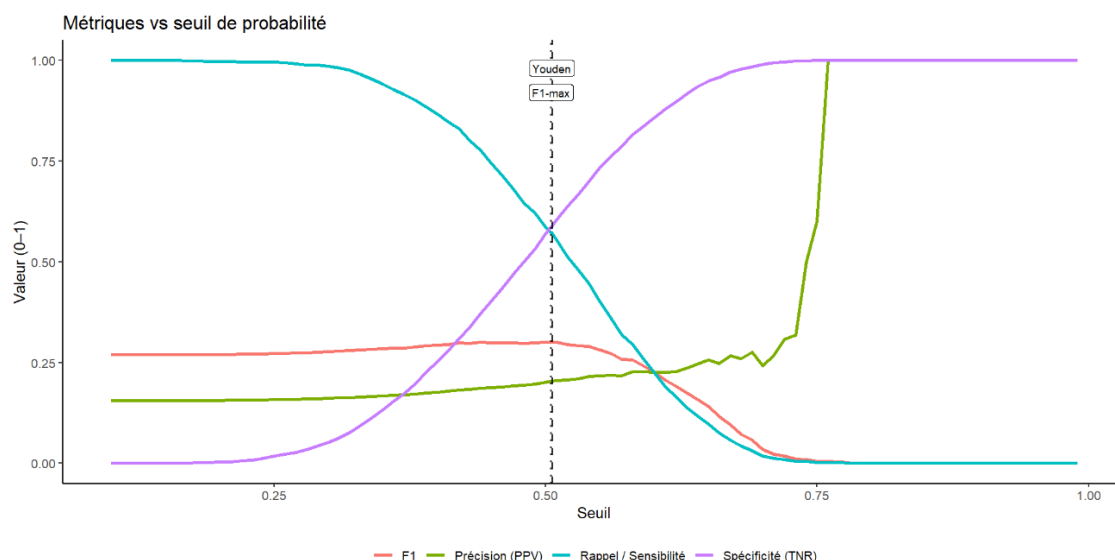


Figure c: métriques en fonction du seuil (Source : données publiques LoanClub + traitement personnel)

Le **choix du seuil** doit refléter les priorités de l'entreprise. Si l'objectif est de **capter plus de défauts**, on choisira un seuil un peu **plus bas** que le compromis (on gagne en rappel en acceptant davantage de fausses alertes). Si l'objectif est de **réduire les fausses alertes** et la charge d'instruction, on montera le seuil au prix d'un rappel plus faible.

Deux approches sont alors possibles pour Loan Club:

### Approche 1 :

Fixer dans un premier temps un seuil qui permet de filtrer les emprunteurs les plus risqués qui seront refusé de la plateforme avant d'attribuer à chaque client acceptés une catégorie de risque relative. Cela permettrait de rassurer les prêteurs de la plateforme et potentiellement augmenter le taux de cagnottes ayant atteint leur objectif.

Il faut cependant garder en tête que le présent rapport n'a pas pour objectif de proposer une valeur pour ce seuil. D'une part parce que nous n'avons pas accès aux données de coûts et bénéfices de LoanClub, d'une autre part parce que la base de données fournie pour ce travail est tronquée. En effet, puisque Loanclub effectue déjà un premier filtrage des emprunteurs avant d'accéder à la plateforme, il est raisonnable de penser que nous n'avons en notre possession que les dossiers qui ont déjà été acceptés et qui ont donc un niveau de risque relativement modéré.

### Approche 2 :

Ne pas appliquer de filtrage (au-delà de celui déjà existant) mais opter pour une catégorisation différente qui serait plus exigeante avec les clients les moins risqués (cela permettrait de faire baisser le taux de défauts des clients jugés comme non risqués rassurant ainsi les prêteurs manifestant une aversion au risque) mais qui l'est moins avec les emprunteurs au profil le plus risqués. Cette souplesse permettrait de classer

moins d'emprunteurs dans les catégories les plus risquées et de ce fait de faire baisser le taux de clients classé en F et G qui remboursent leur prêt. La prochaine section illustre cette approche.

## Résultats scoring

### Distribution du score (échantillon test)

n	Moyenne	Écart-type	Min	Q1	Médiane	Q3	Max
8000	61.55	10.42	24	54	62	69	93

La plupart des scores se situent entre 55 et 70 ; les scores > 85 sont rares. Cela colle avec des coupes A→G où B,C et D concentrent une large part du portefeuille.

Le graphique ci-dessous montrent comment les scores issus de notre modèle s'alignent avec les catégories grade de LoanClub.

On observe que la moyenne et la médiane du score des individus dont la variable grade prend une modalité associée aux risques faibles est plus faible que celle des individus associés à un risque fort. En d'autres termes, plus l'individu est jugé risqué par LoanClub, plus son score aura tendance à être élevé. Notre score est donc cohérent avec les prédictions de LoanClub.




Figure d: Boxplot score vs grade (Source : données publiques LoanClub + traitement personnel)

## Fiche de scoring

Nous reportons ici la fiche de scoring qui permet de voir la contribution de chaque modalité au score. Elle assure ainsi une transparence sur les critères de classification des clients.

**Table 3: Grille de score construite**

variable	level	coef	points
annual_inc_q	[8 000 ; 45 000]	0.51320387	12.56
annual_inc_q	(45 000 ; 62 000]	0.42075363	10.30
annual_inc_q	(62 000 ; 86 000]	0.24510739	6.00
annual_inc_q	(86 000 ; 1e+06]	0.00000000	0.00
avg_cur_bal_q	[0 ; 3 020]	0.28188846	6.90
avg_cur_bal_q	(3 020 ; 8 302]	0.21849649	5.35
avg_cur_bal_q	(8 302 ; 20 286]	0.03914093	0.96
avg_cur_bal_q	(20 286 ; 329 278]	0.00000000	0.00
chargeoff_bin	0	0.70684128	17.31
chargeoff_bin	1+	0.00000000	0.00
dti_q	(16.7 ; 22.5]	0.40743389	9.98
dti_q	(22.5 ; 35]	0.36792548	9.01
dti_q	(11.3 ; 16.7]	0.20933595	5.13
dti_q	[0 ; 11.3]	0.00000000	0.00
inq_last_6mths_bin	1+	0.25597057	6.27
inq_last_6mths_bin	0	0.00000000	0.00
num_accts_ever_120_pd_cat	1+	0.08047637	1.97
num_accts_ever_120_pd_cat	0	0.00000000	0.00
num_actv_bc_tl_cat	6+	0.48602489	11.90
num_actv_bc_tl_cat	3-5	0.11967622	2.93
num_actv_bc_tl_cat	0-2	0.00000000	0.00
num_bc_sats	0-3	0.22611968	5.54
num_bc_sats	4-6	0.17457489	4.27
num_bc_sats	7+	0.00000000	0.00
purpose_group	Travaux_Autres	0.33716521	8.25
purpose_group	Consolidation	0.22202719	5.44
purpose_group	Credit_Consommation	0.00000000	0.00
region	Nord-Est	0.24943878	6.11
region	Midwest	0.20086450	4.92
region	Sud	0.16136673	3.95
region	Ouest	0.00000000	0.00
verification_status	Source Verified	0.53987997	13.22
verification_status	Verified	0.46641379	11.42
verification_status	Not Verified	0.00000000	0.00

Lecture : un individu présentant un ratio d'endettement (DTI) compris entre 16,7 % et 22,5 %, dont la source de revenu est vérifiée, et qui contracte un prêt pour consolider ses dettes, obtient un score total de 25,82 points (soit 9,42 + 11,08 + 5,32), à condition que l'ensemble de ses autres caractéristiques correspondent aux modalités de référence.

En revanche, si la vérification du revenu est effectuée directement par LoanClub (“source verified”), son score s’élève à 27,7 points ( $9,42 + 12,96 + 5,32$ ).

Ces résultats confirment les tendances attendues : un revenu plus faible, un niveau d’endettement élevé, des soldes modestes, un nombre important de demandes de crédit récentes, ainsi que des motifs d’emprunt liés à la consommation ou aux travaux, sont systématiquement associés à un risque de défaut accru

Un doute persiste pour la variable `verification_satatus` car la variable de référence n’est pas `verified` mais `not verified`. Autre problème : `source verified` est jugé par le modèle comme étant plus risquée que `verified`, cela peut paraître contre intuitif mais des résultats similaires ont déjà été trouvés par Benjamin Director (2015). L’une des hypothèses suppose que cela viendrait d’un effet de sélection. LoanClub n’effectuant de vérification que si le dossier présente un certain risque.

## Catégorisation du score en classes A-G

### Seuils appliqués

$$A = [0 - 50), B = [50 - 55), C = [55 - 60), D = [60 - 70), E = [70 - 80), F = [80 - 85), G = [85 - 100]$$

### Répartition sur échantillon test

A	B	C	D	E	F	G
1 042	972	1 284	<b>2 840</b>	<b>1 598</b>	219	45

Tableau 4:(Source : données publiques LoanClub + traitement personnel)

Le découpage place beaucoup d’observations en **D–E** (risque moyen à élevé) et très peu en **F–G** (risque très élevé). Si l’objectif est de **renforcer davantage la sélectivité** en haut risque, on peut **abaisser légèrement** les seuils **F/G**.

### Comparaison avec la notation « grade » existante

Une première façon de comparer nos catégories avec celle préexistante est de comparer les prédictions du modèle à celles du modèle de LoanClub. Pour ce faire nous construisons cette table ci-après :

**Table de correspondance**

Pred \ Obs	A	B	C	D	E	F	G
A	30.9%	17.4%	8.8%	6.5%	4.2%	2.4%	0.0%
B	15.3%	15.0%	11.4%	9.1%	9.2%	4.8%	1.5%
C	17.5%	17.6%	16.0%	15.0%	13.0%	9.7%	11.9%
D	26.6%	33.4%	39.1%	37.6%	35.7%	39.7%	47.8%
E	9.1%	14.7%	21.3%	26.1%	30.8%	37.0%	34.3%
F	0.5%	1.5%	2.9%	4.9%	5.8%	4.5%	1.5%
G	0.1%	0.3%	0.4%	0.8%	1.2%	1.8%	3.0%

Lecture (pourcentages en rouge) : 30.9 % des individus classé en grade A par le modèle initial de LoanClub ont été classé en A par notre modèle. 37.6 % des individus classé en grade D par le modèle initial de LoanClub ont été classé en D par notre modèle.

Les résultats sont globalement cohérent. Les individus les moins risqués selon le modèle de LoanClub ont souvent été classés dans des catégories les moins risqués par notre modèle. L'inverse n'est pas parfaitement vrai mais c'est le résultat recherché par notre modèle à savoir plus de souplesse pour les plus risqués et plus de rigueur pour les moins risqués.

Pour évaluer la capacité de notre modèle à remplir notre objectif, nous avons défini les métriques suivantes :

**M1** : défaut classé A/B (faux « bons »)  
**M2** : non-défaut classé F/G (faux « très risqués »)  
**M3** : M1 + M2 (sur l'ensemble)

Schéma	M1 ( # / % défauts )	M2 ( # / % non-défauts )	M3 ( # / % total )
grade (observé)	312 (25.0 %)	280 (4.15 %)	592 (7.40 %)
score (grade_by_score)	180 ( 14.4 %)	191 (2.83 %)	371 ( 4.64 %)

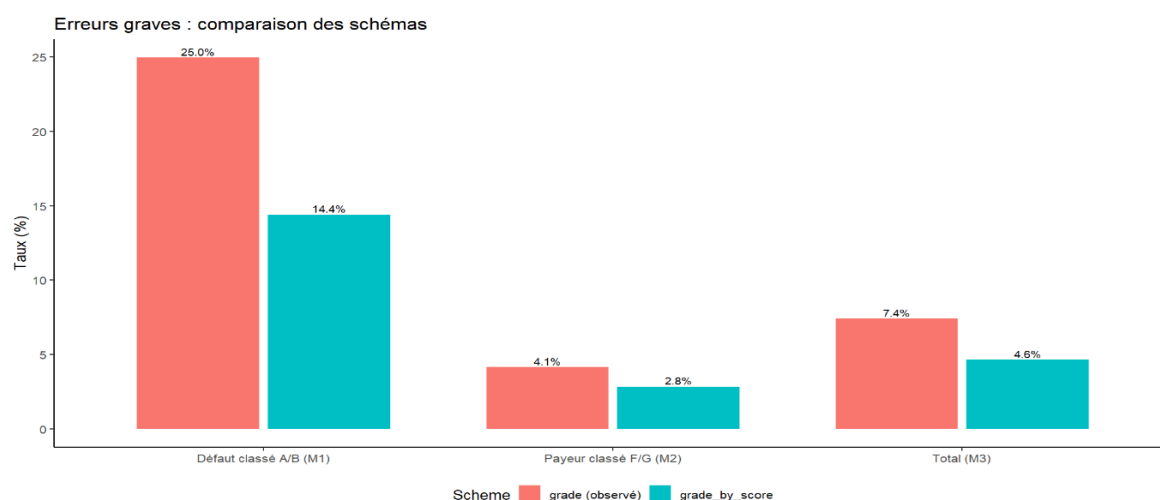


Figure e : Erreurs graves grade vs grade\_by\_score (Source : données publiques LoanClub + traitement personnel)

La catégorisation du score réduit donc comme nous pouvons le voir les erreurs critiques : moins de défauts en A/B et moins de payeurs en F/G. Notre modèle remplit donc les objectifs que nous nous sommes fixés.

## CONCLUSION

Cette étude montre qu'un modèle de scoring simple (régression logistique) appliqué à 20 000 prêts de la plateforme LoanClub (taux de défaut 15,4 %) permet de classer correctement le risque des emprunteurs, de manière claire et utilisable. Les facteurs qui comptent le plus sont la durée et le montant du prêt, ainsi que la situation financière de l'emprunteur (revenus, endettement, stabilité professionnelle, demandes de crédit récentes). Plus la contrainte budgétaire est forte, plus le risque de défaut augmente. Le score (0–100) et la grille A à G qui en découlent sont cohérents avec l'historique et réduisent nettement les erreurs de classement les plus coûteuses.

Deux limites sont à garder en tête : la base ne contient que des prêts acceptés (biais de sélection) et nous ne disposons pas encore de données de coûts/recettes pour fixer un seuil optimal. En pratique, nous recommandons de déployer la grille A→G comme aide à la décision, d'ajuster le seuil selon l'objectif (réduire les défauts ou optimiser la tarification), et de suivre régulièrement les indicateurs de performance.



## REFERENCES BIBLIOGRAPHIQUES

Altair. (2022, 16 mai). *Credit Scoring Series Part One: Introduction to Credit Scoring* [Article de blog]. Altair. Consulté à l'adresse <https://altair.com/blog/articles/credit-scoring-series-part-one-introduction-to-credit-scoring>

Director, B. (2015). *The role of unverifiable information in online peer-to-peer lending* [Unpublished honors thesis]. University of North Carolina, Department of Economics.

Jagtiani, J., & Lemieux, C. (2019). *The Roles of Alternative Data and Machine Learning in Fintech Lending: Evidence from the LendingClub Consumer Platform* (Working Paper No. 18-15R). Federal Reserve Bank of Philadelphia. Consulté à l'adresse <https://www.philadelphiafed.org/-/media/frbp/assets/working-papers/2018/wp18-15r.pdf>

Nguyen, V., Charaf, A., & Germini, E. (2023). *Scoring d'octroi par Machine Learning interprétable ?* [Étude interne]. Nexialog Consulting. Consulté à l'adresse <https://www.nexialog.com/wp-content/uploads/2023/01/Nexialog-Consulting-scoring-par-Machine-Learning-interpretable.pdf>

World Bank Group. (2019). *Credit Scoring Approaches: Guidelines*. Washington, DC : *International Committee on Credit Reporting, World Bank*. Consulté à l'adresse <https://thedocs.worldbank.org/en/doc/935891585869698451-0130022020/original/CREDITSCORINGAPPROACHESGUIDELINESFINALWEB.pdf>